



AT&T : détecteur de spams

Bloc 4 - Deep Learning





Quel détecteur pour les SMS indésirables ?

- Problématique : trop de SMS indésirables (spams) reçus par les utilisateurs
- Situation actuelle : AT&T les signale à la main
- Solution envisagée : une détection automatique, à partir du seul texte du SMS
- Livrable : un notebook qui entraîne le modèle et mesure sa performance

Exemple de spam

« Free entry in 2 a wkly comp to win FA Cup final... »

Exemple de message normal


« Nah I don't think he goes to usf, he lives around here though »

Deux questions

1. Peut-on reconnaître un spam à partir de son seul texte ?
2. Avec quelle fiabilité, et avec quelles erreurs ?



Les données : 1 SMS sur 8 est un spam



■ Messages normaux ■ Spams

5 572
SMS classés


– 403
doublons
supprimés

5 169
SMS conservés

Un détecteur qui répondrait toujours « message normal » aurait déjà 87 % de bonnes réponses... sans rien détecter.



Comment le détecteur lit un SMS





Résultats sur 776 SMS jamais vus

88 %

des spams détectés
(86 sur 98)


93,5 %

des alertes justifiées
(86 sur 92)

< 1 %

de messages normaux
bloqués à tort
(6 sur 678)

Modèle 1 : matrice de confusion (test)





Deux types d'erreurs, un choix pour AT&T

12 spams non détectés

Un spam reste une nuisance pour l'utilisateur

Exemple : « Money i have won wining number 946 wot do i do next »

6 messages normaux bloqués

L'utilisateur perd un message légitime

Exemple : « Your bill at 3 is £33.65 so thats not bad! »

Le curseur

Le seuil de 50 % peut être relevé ou abaissé : bloquer plus de spams au prix de plus de fausses alertes, ou l'inverse.



Conclusion

Valeur immédiate

- Oui : on peut repérer les spams à partir du seul texte du SMS
- Les résultats de notre détecteur : 88 % des spams détectés, moins de 1 % de messages normaux bloqués à tort

Pour aller plus loin

- Régler le seuil selon la priorité d'AT&T
- Tester des modèles déjà entraînés sur du texte (transfer learning)
- Valider sur de vrais SMS

Des questions ?

S. Hardy

